

神经网络方法

1. 多层前向神经网络原理介绍

多层前向神经网络(MLP)是神经网络中的一种,它由一些最基本的神经元即节点组成,下面图1就是这样一个网络。这种网络的结构如下:网络由分为不同层次的节点集合组成,每一层的节点输出到下一层节点,这些输出值由于连接不同而被放大、衰减或抑制。除了输入层外,每一节点的输入为前一层所有节点输出值的和。每一节点的激励输出值由节点输入、激励函数及偏置量决定。

如图1所示,输入模式的各分量作为第*i*层各节点的输入,这一节点的输出,或者完全等于它们的输入值,或由该层进行归一化处理,使该层的输出值都在+1或-1之间。




图1 多层前向神经网络

在第*j*层,节点的输入值为:

$$net_j = \sum w_{ji} o_i + \theta_j \quad (1)$$

式中 θ_j 为阈值,正阈值的作用将激励函数沿*x*轴向左平移.

节点的输出值为:

$$o_j = f(net_j) \quad (2)$$

式中*f*为节点的激励函数,通常选择如下 Sigmoid 函数:

$$f(x) = \frac{1}{1 + \exp(-x)} \quad (3)$$

在第 k 层的网络节点输入为:

$$net_k = \sum w_{kj} o_j + \theta_k \quad (4)$$

而输出为:

$$o_k = f(net_k) \quad (5)$$

在网络学习阶段, 网络输入为模式样本 $x_p = \{x_{pi}\}$, 网络要修正自己的权值及各节点的阈值, 使网络输出不断接近期望值 t_{pk} , 每做一次调整后, 换一对输入与期望输出, 再做一次调整, 直到满足所有样本的输入与输出间的对应。对每一个输入的模式样本, 平方误差 E_p 为:

$$E_p = \frac{1}{2} \sum_k (t_{pk} - o_{pk})^2 \quad (6)$$

而对于全部学习样本, 系统的总误差为:

$$E = \frac{1}{2p} \sum_p \sum_k (t_{pk} - o_{pk})^2 \quad (7)$$

在学习过程中, 系统将调整连接权和阈值, 使 E_p 尽可能快地下降。

2 Matlab 相关函数介绍

2.1) 网络初始化函数

`net=newff([x_m, x_M], [h_1, h_2, \dots, h_k], [f_1, f_2, \dots, f_k])`

其中, x_m 和 x_M 分别为列向量, 存储各个样本输入数据的最小值和最大值; 第 2 个输入变量是一个行向量, 输入各层节点数; 第 3 个输入变量是字符串, 代表该层的传输函数。

常用 `tansig` 和 `logsig` 函数。其中

$$\text{tansig}(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}}, \text{logsig}(x) = \frac{1}{1 + e^{-x}}$$

除了上面方法给网络赋值外, 还可以用下面格式设定参数。

`Net.trainParam.epochs=1000` 设定迭代次数

`Net.trainFcn='traingm'` 设定带动量的梯度下降算法

2.2)网络训练函数

`[net,tr,Y1,E]=train(net,X,Y)`

其中 X 为 $n \times M$ 矩阵, n 为输入变量的个数, M 为样本数; Y 为 $m \times M$ 矩阵, m 为输出变量的个数。 X , Y 分别存储样本的输入输出数据。 net 为返回后的神经网络对象, tr 为训练跟踪数据, $tr.perf$ 为各步目标函数值。 $Y1$ 为网络的最后输出, $E1$ 为训练误差向量。

2.3)网络泛化函数

`Y2=sim(net,X1)`

其中 $X1$ 为输入数据矩阵, 各列为样本数据。 $Y2$ 为对应输出值。

3.神经网络实验

3.1 函数仿真实验

产生下列函数在 $[0,10]$ 区间上间隔为 0.5 的数据, 然后用神经网络进行学习。
并推广到 $[0,10]$ 上间隔为 0.1 上各点的函数值。并分别作出图形。

$$y = 0.2e^{-0.2x} + 0.5 * e^{-0.15x} \cdot \sin(1.25x) \quad 0 \leq x \leq 10$$

Matlab 程序:

```
x=0:0.5:10;
```

```
y=0.2*exp(-0.2*x)+0.5*exp(-0.15*x).*sin(1.25*x);
```

```
plot(x,y) %画原始数据图
```

```
net.trainParam.epochs=5000; %设定迭代步数
```

```
net=newff([0,10],[6,1],{'tansig','tansig'}); %初始化网络
```

```
net=train(net,x,y); %进行网络训练
```

```
x1=0:0.1:10;
```

```
y1=sim(net,x1); %数据泛化
```

```
plot(x,y,'*',x1,y1,'r'); %作对比图
```

从图形上看, 神经网络输出的值比原始数据的曲线光滑。说明神经网络对该函数的学习效果很好。




图2 原始与对比数据图

实验2 MCM89A 蠓的分类

有两种蠓 Af 和 Apf。根据它们的触角(mm)和翼长(mm)进行区分。现有 9 只 Af 和 6 只 Apf。样本数据如下：

表 2.19 9 只 Af 的触角和翼长

触角	1.24	1.36	1.38	1.38	1.38	1.40	1.48	1.54	1.56
翼长	1.72	1.74	1.64	1.82	1.90	1.70	1.82	1.82	2.08

表 2.20 6 只 Apf 的触角和翼长

触角	1.14	1.18	1.20	1.26	1.28	1.30
翼长	1.78	1.96	1.86	2.0	2.0	1.96

另有 3 只待判的蠓,触角和翼长数据为:(1.24,1.80),(1.28,1.84),(1.40,2.04)。试对它们进行判断。

这里我们可用三层神经网络进行判别。

输入为 15 个二维向量,输出也为 15 个二维向量。其中 Af 对应的目标向量为(1,0), Apf 对应的目标向量为(0,1)。

Matlab 程序:

```
x=[1.24, 1.36, 1.38, 1.38, 1.38, 1.40, 1.48, 1.54, 1.56, 1.14, 1.18, 1.20, 1.26, 1.28, 1.30;
    1.72, 1.74, 1.64, 1.82, 1.90, 1.70, 1.82, 1.82, 2.08, 1.78, 1.96, 1.86, 2.0, 2.0, 1.96];
y=[1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0;
    0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1];
xmin=min(x'); %求各指标最小值
xmax=max(x'); %求各指标最大值
```

```

net.trainParam.epochs=2500; %设定迭代步数
net=newff([xmin',xmax'],[5,2],{'logsig','logsig'}); %初始化网络
net=train(net,x,y); %进行网络训练
x1=[1.24,1.28,1.40;
    1.80,1.84,2.04]; %待分样本
y1=sim(net,x1); %数据泛化

plot(x(1,1:9),x(2,1:9),'*',x(1,10:15),x(2,10:15),'o',x1(1,:),x1(2,:), 'p') %画
原始数据图
grid on

```




图3 Af, Apf及待分样本数据图

三个样本输出值为:

```

y1=0.1235    0.8995    0.0037
    0.8785    0.0951    0.9986

```

以两个分量越靠近1就判断为哪一类。从该结果看，第二个样本分为Af；而第一和第三个样本分为Apf。但由于每次训练初始参数的随机性，另外待判3个样本在两类的临界区，导致不同的训练结果会有差异。这也正常。